

B01 / SCORE COMPOSITION

01 玩家满意度 · 55%



02 产品健康度 · 45%



03 产品优势 · 加成项



04 结果可信度 · 折扣系数



| SCORING SYSTEM / DESIGN SPEC

GamePulse AI Evaluation Framework

Version 2.0

DESIGNED & DEVELOPED BY YIHAN YAO

■ PLAYER SATISFACTION

■ PRODUCT HEALTH

■ CONFIDENCE-ADJUSTED

目录

01	评分框架简介	OVERVIEW
02	Evaluation Workflow	PIPELINE
03	数据来源	SOURCE
04	数据清洗流程	CLEANING
05	评论分类标准	CATEGORY
06	情感分析标准	SENTIMENT
07	产品健康度计算	HEALTH SCORE
08	产品优势识别	STRENGTH BONUS
09	结果可信度计算	CONFIDENCE
10	Overall Score 计算方法	FORMULA
11	等级说明	GRADE
12	数据局限性	LIMITATIONS
13	Reference List	REFERENCES

评分框架简介

GamePulse AI Evaluation 的目标不是给游戏打一个分数，而是建立一套统一、可复现的评价标准，使不同游戏、不同版本、不同国家市场之间能够进行横向比较。

Google Play 的星级只能告诉你玩家给了多少分，无法回答玩家究竟满意什么、最大的问题出在哪、当前版本是否健康、商业化是否受到质疑。GamePulse AI Evaluation (GAE) 把大量非结构化的评论文本，转化为统一、可比较的产品质量指标。

■ 确定性优先

凡是能用公式计算的环节，一律使用固定公式，而不是让 AI 每次临场判断分数——保证同一批数据任何时候重跑，结果一致。

■ AI 只负责标注，不负责打分

AI 的角色被限定在语义理解层：分类、情感判断、严重程度标注。最终分数由确定性公式基于这些标注计算得出。

■ 可信度与质量分离

“这批数据够不够可信”和“这款产品好不好”是两个不同的问题，因此可信度不再与其他维度加权混合，而是作为独立的折扣系数作用于最终分数。

GamePulse AI Evaluation 不等同于 Google Play 官方评分，也不代表产品的商业表现，它衡量的是「本次抓取的评论样本所反映出的产品状态」。

Evaluation Workflow

整个评分流程分为六个阶段，前五个阶段产出结构化数据，最后一个阶段用确定性公式将其汇总为分数。



数据来源

评论数据来自 Google Play 商店，用户可指定目标游戏、地区与语言范围。

■ 游戏识别

输入 Google Play 商店链接，自动解析应用包名。

■ 市场范围

支持按国家（如美国、日本、韩国）或大区（东亚、东南亚、欧洲、北美等）抓取。

■ 语言范围

可指定评论语言，或选择不限制语言以保留全部评论。

■ 抓取数量

用户自定义目标抓取评论数量，实际抓取数以 Google Play 返回结果为准。

■ GOOGLE PLAY

■ MULTI MARKET

■ LANGUAGE FILTER

数据清洗流程

原始评论在进入 AI 分析前，先经过标准化清洗，保证后续分类与情感分析基于有效样本。

去重

剔除重复评论内容。

去空

删除空评论或仅含星级无文本内容的记录。

异常字符处理

删除乱码、异常符号等干扰内容。

语言过滤（可选）

按用户指定语言过滤，并记录过滤前后数量差异。

标准化

统一格式，便于后续批处理分析。

清洗过程中的每一步都会记录数量变化（抓取数 → 清洗后数 → 语言过滤后数 → 最终有效样本数），这些数字也是「结果可信度」计算的原始输入。

评论分类标准

每条评论由 Claude 归入唯一的主要类别（单标签分类）。

类别	判定标准
整体评价	只表达整体喜欢或不喜欢，没有具体功能指向
游戏玩法	关卡、战斗、机制、策略、数值体验
BUG	崩溃、异常、无法登录、数据丢失、功能失效
性能优化	卡顿、发热、掉帧、加载速度、设备兼容性
氪金	抽卡、价格、付费压力、礼包、商业化设计
UI 体验	界面布局、按钮、信息层级、操作便利性
美术	角色设计、动画、画面、视觉表现
活动运营	活动内容、奖励、版本节奏、运营安排
新手引导	教程、学习成本、早期成长体验
社交	公会、好友、聊天、组队、社区体验
其他	无法稳定归入以上类别的评论

当前为单标签分类：一条同时提到多个主题的评论，只进入其中一个主类别，可能损失部分次要信息，属于已知局限（详见第 12 节）。

情感分析标准

情感	判定标准
正面	明确认可、满意、推荐，或赞扬玩法、美术、活动等；即使有轻微建议，但整体态度积极
中性	主要陈述事实、态度不明显、优缺点相对平衡，或信息不足以判断明显情感
负面	明确不满、批评、投诉，或涉及 BUG、卡顿、登录失败、数据丢失、付费争议、退游等强烈负面表达

情感分类与主题分类在同一次 Claude 批处理请求中输出，两者是逻辑上独立的字段。

产品健康度计算

健康度回答的问题是：产品当前是否存在影响体验的重要风险？计算分两层：AI 只负责标注，公式负责计算。

LAYER 01 · AI 严重度标注

对每条归入风险类别（BUG / 性能 / UI / 氪金 / 新手引导等）的评论，AI 额外输出严重程度标签与是否阻塞核心流程。

等级	定义	权重
S1 轻微	影响体验但不影响核心功能，玩家可正常游玩	1
S2 中等	造成明显不便，但存在绕过方法	3
S3 严重	影响核心玩法体验，难以绕过	7
S4 阻塞	导致玩家无法继续游戏（闪退、无法登录、数据丢失）	15

LAYER 02 · 确定性公式计算

风险扣分 = $\sum$ （该等级评论数 × 该等级权重） / 有效评论总数 × 标准化系数
// 标准化系数由历史数据回归校准，控制扣分范围

阻塞加成扣分 = 若 S4 占比 > 5%，额外扣 10 ~ 15 分
// 阻塞性问题的影响是非线性的，不能只按数量线性扣分

产品健康度 = $\max(0, 100 - \text{风险扣分} - \text{阻塞加成扣分})$

这一设计解决的核心问题：10 条「按钮不够直观」与 10 条「无法登录」评论数量相同，但通过 S1/S4 权重差异（1 vs 15），会产生完全不同的健康度影响。

产品优势识别

回答的问题：玩家为什么喜欢这款游戏？AI 从正面评论中识别核心优势信号。

识别维度

核心玩法、美术表现、角色设计、剧情、活动运营、社区体验等正向信号。

集中度判断

如果优势高度集中在少数几个维度，说明产品具有明确、可辨识的竞争力。

产品优势不再作为与健康度平行的独立权重项，而是作为 Base Score 之上的加成项（最高 +5 分）。

这样设计的原因：若优势与健康度平行加权，「美术很好」可能在数值上抵消「频繁闪退」这类阻塞性问题，掩盖真正的风险。加成项的形式保证阻塞性问题始终优先被看见。

结果可信度计算

回答的问题：本次分析结果是否值得相信？——这评价的是分析本身的可靠性，不评价产品好坏，因此不再计入 Overall Score 的加权求和，而是作为独立的折扣系数。

有效样本量

最终进入分析的评论数量，样本越少，置信度越低。

语言覆盖率

评论语言分布是否集中，是否存在因语言过滤损失大量样本的情况。

泛化评论占比

「整体评价」「其他」等低信息类别的占比，占比越高，可分析的具体信息越少。

分类一致性

类别是否存在明显异常集中或与情感标签矛盾的情况。

可信度系数 = f (有效评论数, 语言覆盖率, 泛化评论占比, 分类一致性)

// 输出区间 0.7 ~ 1.0

0.7 数据不足，结果仅供参考

0.85 数据基本充分，结果可作为主要参考

1.0 数据充分，结果可信度高

样本量不足代表「这个分数不确定」，不代表「产品质量差」，两者必须分开表达，因此可信度以折扣系数、而非加权分量的形式作用于最终结果。

Overall Score

计算方法

四个维度不再是简单的四项加权求和，而是「基础分 × 置信折扣」的两层结构。

Base Score = 55% × 玩家满意度 + 45% × 产品健康度 + 产品优势加成 (≤ 5)

Overall Score = Base Score × 可信度系数

// 可信度系数 ∈ [0.7, 1.0], 详见第 09 节

玩家满意度

基于 Positive / Neutral / Negative 比例生成，Neutral 计为部分正向。

产品健康度

基于严重度加权风险扣分与阻塞加成扣分计算，详见第 07 节。

这套两层结构使得低样本量的分析会显示为「分数尚可，但可信度较低，建议增加样本」，而不是把不确定性直接、不透明地混进一个单一数字里。

等级说明

S	90 – 100	优秀 · 玩家高度满意，产品健康，无明显阻塞性问题
A	80 – 89	良好 · 整体表现稳定，存在少量待优化问题
B	70 – 79	中上 · 基本可用，部分维度需要关注
C	60 – 69	一般 · 存在较明显的体验或健康度问题
D	< 60	建议重点优化 · 存在阻塞性问题或玩家满意度明显偏低

Grade 仅基于 Overall Score（已经过可信度折扣）划分，因此低可信度场景下的高分会先被折扣系数压低，再进行分级，不会出现「样本不足却被评为 S 级」的情况。

数据局限性

■ 单标签分类

一条同时涉及多个主题的评论仅归入一个主类别，可能损失次要信息。

■ 严重度标注尚未经过人工校准

S1—S4 标签由 AI 单次判断产出，尚未通过重复标注或人工抽检验证一致率。

■ 语言分布统计不完整

「不限制语言」模式下，目前尚未输出完整的语言分布（如日语/英语/中文各占比），后续需增加自动语言识别。

■ 标准化系数依赖历史数据

健康度公式中的标准化系数需要用一批历史项目结果回归校准，当前版本为初始设定值，会随着数据积累持续调优。

■ 非官方评分

Overall Score 不代表 Google Play 官方评分，也不直接等同于产品商业表现，仅用于辅助产品评估与版本分析，AI 分析结果应作为决策参考而非唯一结论。

Reference List

本框架的设计理念参考了以下用户体验度量、情感分析与移动应用商店评论分析相关的公开方法论与文档。

- 01 Reichheld, F. F. (2003). The One Number You Need to Grow. *Harvard Business Review*, 81(12), 46–54.
净推荐值 (NPS) — 单一指标衡量客户满意度的设计思路
- 02 Rodden, K., Hutchinson, H., & Fu, X. (2010). Measuring the User Experience on a Large Scale: User-Centered Metrics for Web Applications. *Proceedings of CHI 2010*, ACM.
HEART Framework — 多维度用户体验度量体系
- 03 Pang, B., & Lee, L. (2008). Opinion Mining and Sentiment Analysis. *Foundations and Trends in Information Retrieval*, 2(1–2), 1–135.
情感分析方法论基础
- 04 Google Play Console Help. Ratings and Reviews Overview.
support.google.com/googleplay/android-developer
- 05 Anthropic. Claude API Documentation — Messages & Batch Processing.
docs.claude.com
- 06 google-play-scraper (Python Library) Documentation.
github.com/JoMingyu/google-play-scraper

GamePulse AI Evaluation Framework 的评分权重、严重度分级与折扣系数设计为原创设计，以上文献仅作为方法论参考，不代表框架直接采用其计算公式。